Постобработка OCR паспорта РФ

Результат: для test подготовлены **949 accept (47,45%) и 1051 reject**. Прогноз — **около 8 ошибочно принятых документов**. Нулевая ошибка не достигнута. Решение работает на CPU, без интернета и сторонних библиотек, Python 3.10+.

Алгоритм и доработка

Строки сортируются по координатам; геометрия рамок выявляет пропуски строк. Проверяются формат МЧЗ, четыре контрольные цифры, согласованность ФИО и числовых полей с визуальной зоной. Разрешены ограниченные замены неуверенных символов при уверенном подтверждении другой зоной. Отсутствующие числовые поля восстанавливаются только при однозначности; век рождения не выбирается по критерию действительности паспорта. Проверяются даты на **01.10.2026**, возраст выдачи и замена после 20/45 лет с 90-дневным периодом. Статус утраты или аннулирования из входных данных установить нельзя.

Исправлена неоднозначная словарная коррекция: прежнее `ПМВД` → `ОМВД` игнорировало вариант удаления буквы `ПМВД` → `МВД`. Теперь при поиске конкурентов учитываются замены, вставки и удаления; неоднозначность приводит к отказу. Применяются только однозначные замены; исправления не получают искусственную уверенность 1,0. Этот режим доступен через `-dictionary-mode safe`.

По умолчанию словарные исправления отключены. Название органа выдачи принимается по исходному тексту и порогу уверенности; справочник используется для проверки наличия кода. Это выбранный консервативный режим, а не утверждение, что исправления всегда вредны. Во время обработки train-разметка не читается.

Эксперименты и выбор

`experiments.py` проверяет **141 конфигурацию**: 135 сочетаний и 6 контрольных режимов. Для места рождения и органа выдачи сравниваются минимум, среднее и произведение посимвольных оценок. Произведение — эвристика, не вероятность: калибровка и независимость ошибок не установлены. Остальные проверки одинаковы.

Сетка порогов: минимум — 0,85/0,90/0,95/0,98/0,99; среднее — 0,95/0,98/0,99/0,995/0,999; произведение — 0,50/0,70/0,80/0,90/0,95. Для `mobile_v2` отдельно проверяются 0,98/0,995/1,0. Каждый вариант проверяется со словарём, без словаря и без замен символов; восстановление отсутствующих числовых полей сохраняется.

Параметры выбираются на прежней рабочей части **2390 документов**: минимизируется верхняя граница 95%-го интервала Уилсона для доли ошибок среди принятых; при равенстве выбирается большее покрытие. Критерий учитывает объём проверки, чтобы не предпочитать крошечную выборку без ошибок. Это эвристика выбора после поиска, **не гарантия риска**. Test в выборе не участвует.

Режим	Принято / 3000	С ошибкой
Предыдущая версия	1478	12
Исправленный словарь, минимум 0,95	1477	11
Без словаря, минимум 0,95 — выбран	**1400**	**10**
Без словаря, минимум 0,90	1465	22
Без словаря, минимум 0,98	1109	10
Без словаря, среднее 0,995	1470	52
Без словаря, произведение 0,90	1204	10
Без замен символов, минимум 0,95	1299	10
Исправленный словарь, без геометрии	1508	42
Исправленный словарь, порог 0,95 всем источникам	1510	23

В таблице, кроме последней строки, порог `mobile_v2` равен 1,0. Полные результаты, разрезы по источникам, ошибки и хеши файлов — в `experiments/results.csv` и `experiments/results.json`; выбранные параметры — в `selected_policy.json` в той же папке.

Проверка и прогноз

Разбиение воспроизводится через `int(sha256(doc_id), 16) % 5`; остаток 0 — прежние 610 отложенных документов. **Они уже изучались при диагностике ошибки словаря**, поэтому результаты доработки на них не являются новой независимой проверкой. Все train-данные ранее анализировались.

При выборе параметров на четырёх из пяти частей режим без словаря выбирается в 4 случаях, безопасный словарь — в одном; минимум 0,95 и порог 1,0 сохраняются во всех пяти. Суммарная проверка на исключённых частях: **1411 принятых, 11 ошибок**. Это оценка устойчивости выбора параметров, а не независимости разработки правил.

Итоговый режим	Всего	Принято	Верно и действует	С ошибкой
Рабочая часть	2390	1123	1114	9
Прежняя отложенная часть	610	277	276	1
Весь train	3000	1400	1390	10

У выбранного режима верхняя оценка риска на рабочей части — **1,516%**, у безопасного словаря — **1,550%**. Превосходство статистически не доказано. Безопасный словарь добавляет 77 принятий: 76 верных и одно расхождение ФИО, которое не создано исправлением названия. По сравнению со старым режимом ошибочных принятий стало на два меньше, но дополнительно отклонены 76 правильных документов. У принятых документов 112 полей изменены относительно OCR и совпали с разметкой; ошибочных изменений не обнаружено. Просроченных по датам среди принятых нет.

Выводы: среднее скрывает ошибки отдельных символов; порог 0,98 теряет покрытие без уменьшения числа ошибок; геометрия существенно помогает обнаруживать неполные поля. Удаление проверки контрольных цифр в контрольном режиме не изменило ответы: на этой выборке другие проверки перекрывают её вклад; это не доказательство ненужности контрольных цифр. Ноль ошибок не получен ни в одной из 141 конфигурации на всём train. У итоговых 10 ошибок девять относятся к ФИО с согласованными VIZ/MRZ и отличающейся разметкой, одна — к месту рождения. Без изображений нельзя определить причину этих расхождений.

В test принято 422 документа `web`, 347 `mobile`, 180 `mobile_v2`. Прогноз по частотам ошибок выбранного режима на всём train: `422 × 6/763 + 347 × 2/511 + 180 × 2/126 = 7,53`, то есть **около 8**. Это оценка на ранее изученных данных; разметки test нет. Учитывается изменение доли `mobile_v2`: 9,7% train против 21,6% test.

Воспроизведение

```
python3 experiments.py --output experiments
python3 postprocess.py data/test_predictions.jsonl answers.jsonl
python3 validate.py --split all --answers train_answers.jsonl
python3 evaluate.py train_answers.jsonl data/train_labels.jsonl
python3 -m unittest -v
```

Прошли **27 тестов**. `evaluate.py` не проверяет даты; это делает `validate.py`. Исходные данные и задание не изменены. Формат МЧЗ: приказ МВД № 773, приложение № 24; сроки: постановление № 2267, пункт 24. Справочник DaData / hflabs, CC BY-SA 4.0: `reference/SOURCE.txt`.